

Predicción de abandono y éxito académico mediante Machine Learning

Carlos Ozuna · Asignatura: Proyecto II: Aprendizaje de Máquina · Dataset: Predict Students' Dropout and Academic Success


Problema y objetivo

El abandono universitario genera consecuencias académicas, económicas y sociales. Es por eso que se desarrollaron modelos de clasificación multiclase para predecir tres estados: Dropout (abandono), Enrolled (matriculado) y Graduate (graduado). El objetivo es apoyar una alerta temprana, orientar el acompañamiento académico,y facilitar la asignación de becas


Datos

Nombre	Predict Students' Dropout and Academic Success
Fuente	UCI Machine Learning Repository – Dataset 697
Tipo de tarea	Clasificación multiclase
Instancias	4.424 estudiantes
Predictores	36 variables
Objetivo	Target
Faltantes	No identificados

Distribucion de clases




Analisis exploratorio



- Graduate:** notas semestrales más altas y concentradas.
- Dropout:** mayor dispersión y numerosos valores cercanos a cero.
- Enrolled:** comportamiento intermedio y heterogéneo.

Metodología



Partición estratificada: 80% entrenamiento (≈3.539) y 20% prueba (885). En entrenamiento se aplicaron preprocesamiento en *pipeline*, validación cruzada estratificada de 5 folds, comparación de modelos y ajuste de los dos mejores.

- One-Hot Encoding para categorías; binarias en 0/1.
- StandardScaler para variables numéricas.
- class_weight="balanced" en Regresión Logística y SVM.
- Pipelines para evitar fuga de información.

Métrica principal: F1-macro, porque pondera por igual las tres clases y evita favorecer a la mayoritaria.

Modelos y comparación inicial

Se evaluaron Regresión Logística, SVM con kernel RBF, Random Forest y red neuronal MLP.

Modelo	Acc.	Prec.	Recall	F1
Reg. Log.	0,7485	0,7083	0,7137	0,7065
SVM	0,7513	0,7170	0,7177	0,7107
Random Forest	0,7697	0,7284	0,6676	0,6767
MLP	0,7414	0,6821	0,6726	0,6760

Random Forest alcanzó la mayor accuracy, pero SVM mostró el rendimiento más equilibrado. Elegir solo por accuracy habría ocultado diferencias entre clases.

Ajuste de hiperparámetros

Modelo	F1 inicial	F1 ajustado	Mejora
Regresión Logística	0,7065	0,7161	+0,0096
SVM	0,7107	0,7235	+0,0128

Regresión Logística: C = 0.001–100, L2, lbfgs.

SVM: kernels lineal/RBF, C = 0.01–100 y gamma = scale, 0.001, 0.01, 0.1. SVM fue el modelo final.

Resultados finales · SVM ajustado

Evaluación independiente sobre 885 estudiantes.

Métrica	Valor
Accuracy	0,7469
Precision macro	0,7178
Recall macro	0,7190
F1-macro	0,7080
F1-weighted	0,7592

Clase	Prec.	Recall	F1
Dropout	0,8522	0,6901	0,7626
Enrolled	0,4310	0,6478	0,5176
Graduate	0,8702	0,8190	0,8438

Discusión y conclusiones

- Graduate fue la clase mejor identificada (F1 = 0,8438).**
- Dropout alcanzó alta precisión (0,8522), pero recall de 0,6901: detectó cerca del 69% de abandonos reales.**
- Enrolled fue la clase más difícil (F1 = 0,5176; precisión = 0,4310), por su carácter intermedio y heterogéneo.**
- SVM ajustado fue el mejor modelo bajo F1-macro. El preprocesamiento y los pipelines fueron decisivos.**
- Al incorporar rendimiento de los dos primeros semestres, el sistema funciona mejor tras iniciar la trayectoria académica que al momento de inscripción.**
- Accuracy por sí sola fue insuficiente: favoreció a Random Forest pese a su menor equilibrio entre clases**

Trabajo futuro

Realizar modelos exclusivos antes del ingreso a las universidades; aplicar selección de variables, balancear los datos, probar otros modelos de ensamblado.

Referencias:

- [1] Realinho et al., UCI Dataset 697, 2021, doi:10.24432/C5MC89.
- [2] Realinho et al., Zenodo, 2021, doi:10.5281/zenodo.5777340.
- [3] Cortes & Vapnik, Machine Learning, 1995.
- [4] Breiman, “Random forests,” 2001.
- [5] Pedregosa et al., JMLR, 2011.
- [6] Fawcett, Pattern Recognition Letters, 2006.